

综合实践报告

课程:机器学习	实验名称:信用卡欺诈检测	日期:4.8
姓名:雷文豪	学号:138022024031	专业班级:人工智能

1 实验目的

信用卡欺诈是指故意使用伪造、作废的信用卡，或冒用他人的信用卡骗取财物的恶劣行为。本次实践的目的在于利用信用卡的历史交易数据，通过数据预处理、变量选择、建模分析预测等方法，构建简单的信用卡反欺诈预测模型，提前发现客户信用卡被盗刷的事件。当有新的用户刷卡信息来的时候，希望你建立的模型能准确地预测出这是**正常的刷卡行为**还是**盗刷行为**。

2 实验内容提要与实验设备

1. 针对待解决问题设计适合的求解方法。
2. 对给定数据集，设计求解过程、编写程序实施求解。
3. 实验结果的分析与确认。
4. 实验设备：个人电脑或便携式电脑，并安装 Windows 等操作系统和编程开发环境。

3 实验内容与步骤

请按照如下步骤完成信用卡反欺诈预测模型，要求在每个步骤后面详细地写出你的解决步骤、代码实现细节、以及相应的运行结果。

3.1 场景分析

请描述任务的具体场景。例如，是监督学习还是非监督学习？是分类问题还是回归问题等。

3.2 数据处理

原始数据为个人交易记录，考虑数据本身的隐私性，已经对原始数据进行了脱敏，无法提供有关数据的原始功能和更多背景信息。因此，只能从数据本身的角度出发进行处理，比如，你可以先检查

数据的完整性、特征之间数值的大小、样本的类别分布情况等。特别是针对类别分布情况，有什么发现？

3.3 特征工程

1. **特征选择**：查看特征分布情况，把不同类别下，特征数值分布相差不大的特征删除，选择在不同信用卡状态下的分布有明显区别的特征变量。
2. **特征缩放**：若某个特征的值和其他特征的值相差较大，则把该特征的数值进行缩放。

3.4 模型建立与训练

这里，采用我们已经学习过的逻辑回归模型和 k -近邻算法。

3.5 模型评估

请根据任务需求，分析你打算采用的模型评估方法和评价指标。

1. 整体思路

信用卡反欺诈预测的核心是通过历史交易数据识别异常行为，核心思路围绕“数据探索-预处理-特征优化-模型训练-评估优化”展开。先排查数据完整性、分析特征分布与类别不平衡问题，为后续处理奠定基础；针对特征数值范围差异大的问题进行标准化，解决类别不平衡（欺诈样本少）问题；通过相关性分析筛选与欺诈行为强相关的特征，剔除冗余信息，降低模型复杂度；分别训练逻辑回归（线性模型，高效可解释）和 KNN（非参数模型，捕捉局部模式），对比两者在二分类任务中的表现；结合类别不平衡特性，采用多维度指标（精确率、召回率、F1-score、AUC-ROC）评估模型，优先保证欺诈样本的识别能力（召回率）。

2. 场景分析

本任务属于监督学习中的二分类问题。数据集包含明确标签（Class列），模型可通过历史标签学习特征与欺诈行为的映射关系；输出结果仅两种状态（正常/欺诈），目标是构建模型对新交易的类别进行预测；实际数据中欺诈样本占比极低（典型占比<1%），存在严重类别不平衡；特征维度高（V1-V28共28个匿名特征），需避免冗余特征影响模型性能。

3. 基于python的代码实现

（1）源代码

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split, GridSearchCV
```

```

from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import (accuracy_score, precision_score, recall_score, f1_score,
                             roc_auc_score, confusion_matrix, roc_curve)
from sklearn.utils import shuffle
from imblearn.over_sampling import SMOTE
import warnings
warnings.filterwarnings('ignore')

# 设置中文显示
plt.rcParams['font.sans-serif'] = ['SimHei']
plt.rcParams['axes.unicode_minus'] = False

# 数据加载与探索
def load_and_explore_data(file_path):

    # 高效读取大数据量CSV
    df = pd.read_csv(file_path, chunksize=10000)
    df = pd.concat(df, ignore_index=True)

    # 数据基本信息
    print("数据形状：", df.shape)
    print("\n缺失值统计：")
    print(df.isnull().sum())

    # 类别分布
    class_dist = df['Class'].value_counts(normalize=True) * 100
    print("\n类别分布 (%)：")
    print(class_dist)
    class_dist.plot(kind='bar', title='交易类别分布 (0=正常, 1=欺诈)')
    plt.show()

    # 特征数值范围
    print("\n特征数值范围 (前5个特征+Amount)：")
    print(df[['Time', 'V1', 'V2', 'V3', 'V4', 'Amount']].describe())

    return df

# 加载数据
df = load_and_explore_data(".csv")

# 数据预处理与特征工程
def preprocess_and_feature_engineer(df):

    # 分离特征与标签
    X = df.drop(['Class', 'Time'], axis=1) # Time为时间戳，与欺诈无直接关联，剔除
    y = df['Class']

    # 特征标准化

```

```

scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
X_scaled = pd.DataFrame(X_scaled, columns=X.columns)

# 特征选择
corr = pd.DataFrame(np.corrcoef(X_scaled.T, y), columns=X.columns +
['Class'])['Class'][:-1]
high_corr_features = corr[abs(corr) > 0.1].index # 筛选相关性绝对值>0.1的特征
X_selected = X_scaled[high_corr_features]
print(f"\n筛选后保留的特征（共{len(high_corr_features)}个）：")
print(high_corr_features.tolist())

# 处理类别不平衡
# SMOTE过采样
smote = SMOTE(random_state=42)
X_resampled, y_resampled = smote.fit_resample(X_selected, y)

# 划分训练集与测试集
X_train, X_test, y_train, y_test = train_test_split(
    X_resampled, y_resampled, test_size=0.2, random_state=42, stratify=y_resampled
)

print(f"\n训练集形状：{X_train.shape}，测试集形状：{X_test.shape}")
print(f"训练集类别分布：{pd.Series(y_train).value_counts(normalize=True) * 100}")

return X_train, X_test, y_train, y_test, scaler, high_corr_features

# 执行预处理
X_train, X_test, y_train, y_test, scaler, selected_features =
preprocess_and_feature_engineer(df)

# 训练逻辑回归和K-近邻模型并调参
def train_models(X_train, y_train):

    # 逻辑回归调参
    lr_params = {'C': [0.001, 0.01, 0.1, 1, 10, 100]}
    lr = LogisticRegression(random_state=42, max_iter=1000)
    lr_grid = GridSearchCV(lr, lr_params, cv=5, scoring='f1', n_jobs=-1)
    lr_grid.fit(X_train, y_train)

    # K-近邻调参
    knn_params = {'n_neighbors': [3, 5, 7, 9, 11, 13, 15]}
    knn = KNeighborsClassifier(weights='distance') # 距离加权
    knn_grid = GridSearchCV(knn, knn_params, cv=5, scoring='f1', n_jobs=-1)
    knn_grid.fit(X_train, y_train)

    # 输出最优参数
    print("\n逻辑回归最优参数：", lr_grid.best_params_)
    print("K-近邻最优参数：", knn_grid.best_params_)

```

```

    return lr_grid.best_estimator_, knn_grid.best_estimator_

# 训练最优模型
lr_model, knn_model = train_models(X_train, y_train)

# 多模型评估与结果对比
def evaluate_models(models, model_names, X_test, y_test):

    # 存储评估结果
    results = pd.DataFrame(columns=['模型', '准确率', '精确率', '召回率', 'F1-score',
    'AUC-ROC'])

    plt.figure(figsize=(10, 6))
    for i, (model, name) in enumerate(zip(models, model_names)):
        # 预测结果
        y_pred = model.predict(X_test)
        y_pred_proba = model.predict_proba(X_test)[:, 1]

        # 计算指标
        acc = accuracy_score(y_test, y_pred)
        prec = precision_score(y_test, y_pred)
        rec = recall_score(y_test, y_pred)
        f1 = f1_score(y_test, y_pred)
        auc = roc_auc_score(y_test, y_pred_proba)

        # 存储结果
        results.loc[i] = [name, acc, prec, rec, f1, auc]

        # 绘制ROC曲线
        fpr, tpr, _ = roc_curve(y_test, y_pred_proba)
        plt.plot(fpr, tpr, label=f' {name} (AUC={auc:.3f})')

        # 混淆矩阵
        cm = confusion_matrix(y_test, y_pred)
        print(f"\n{name} 混淆矩阵: ")
        print(cm)

    # 绘制ROC曲线
    plt.plot([0, 1], [0, 1], 'k--', label='随机猜测')
    plt.xlabel('假阳性率 (FPR)')
    plt.ylabel('真阳性率 (TPR)')
    plt.title('ROC曲线对比')
    plt.legend()
    plt.show()

    # 输出评估结果
    print("\n模型评估结果汇总: ")
    print(results.round(4))
    return results

```

```

# 评估两个模型
models = [lr_model, knn_model]
model_names = ['逻辑回归', 'K-近邻']
evaluation_results = evaluate_models(models, model_names, X_test, y_test)

import joblib

# 保存模型、标准化器和特征列表（用于新数据预测）
joblib.dump(lr_model, 'logistic_regression_fraud.pkl')
joblib.dump(knn_model, 'knn_fraud.pkl')
joblib.dump(scaler, 'scaler.pkl')
joblib.dump(selected_features, 'selected_features.pkl')

# 新数据预测
def predict_new_transaction(transaction_data):

    # 加载保存的组件
    scaler = joblib.load('scaler.pkl')
    selected_features = joblib.load('selected_features.pkl')
    model = joblib.load('logistic_regression_fraud.pkl')

    # 预处理新数据
    transaction_df = pd.DataFrame([transaction_data], columns=scaler.feature_names_in_)
    transaction_scaled = scaler.transform(transaction_df)
    transaction_selected = transaction_scaled[:,
[list(scaler.feature_names_in_.index(f) for f in selected_features)]

    # 预测
    pred = model.predict(transaction_selected)[0]
    pred_proba = model.predict_proba(transaction_selected)[0][1]

    return f"交易预测结果: {'欺诈' if pred == 1 else '正常'}, 欺诈概率:
{pred_proba:.3f}"


# 测试新数据预测
new_transaction = np.random.randn(len(scaler.feature_names_in_))
print("\n新交易预测结果:")
print(predict_new_transaction(new_transaction))

```

(2) 运行结果

```
文件(F) 编辑(E) 选择(S) 查看(V) 转到(G) 运行(R) ... SRC
credit_card_fraud_recognition.ipynb
course7 > credit_card_fraud_recognition.ipynb > # 数据加载与探索
# 加载数据
df = load_and_explore_data("creditcard.csv")
[3] ✓ 1.0s
数据形状: (284807, 31)
缺失值统计:
Time      0
V1         0
V2         0
V3         0
V4         0
V5         0
V6         0
V7         0
V8         0
V9         0
V10        0
V11        0
V12        0
V13        0
V14        0
V15        0
V16        0
V17        0
V18        0
V19        0
V20        0
V21        0
...
Class
0    99.827251
1     0.172749
Name: proportion, dtype: float64
Output is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings...
```

交易类别分布 (0=正常, 1=欺诈)



文件(F) 编辑(E) 选择(S) 查看(V) 转到(G) 运行(R) ...

信用卡欺诈识别.ipynb

course7 > credit_card_fraud_recognition.ipynb > # 数据加载与探索

生成 + 代码 + Markdown | 全部运行 | 重启 | 清除所有输出 | Jupyter 变量 | 大纲 ...

ML-course-env (Python 3.10.20)

0 1 Class

特征数值范围 (前5个特征+Amount):

	Time	V1	V2	V3	V4
count	284807.000000	2.848070e+05	2.848070e+05	2.848070e+05	2.848070e+05
mean	94813.859575	1.168375e-15	3.416908e-16	-1.379537e-15	2.074095e-15
std	47488.145955	1.958696e+00	1.651309e+00	1.516255e+00	1.415869e+00
min	0.000000	-5.640751e+01	-7.271573e+01	-4.832559e+01	-5.683171e+00
25%	54201.500000	-9.203734e-01	-5.985499e-01	-8.903648e-01	-8.486401e-01
50%	84692.000000	1.810880e-02	6.548556e-02	1.798463e-01	-1.984653e-02
75%	139320.500000	1.315642e+00	8.037239e-01	1.027196e+00	7.433413e-01
max	172792.000000	2.454930e+00	2.205773e+01	9.382558e+00	1.687534e+01

Amount

	Amount
count	284807.000000
mean	88.349619
std	250.120109
min	0.000000
25%	5.600000
50%	22.000000
75%	77.165000
max	25691.160000

```
# 数据预处理与特征工程
def preprocess_and_feature_engineer(df):
    # 分离特征与标签
    X = df.drop(['Class', 'Time'], axis=1) # Time为时间戳, 与欺诈无直接关联, 剔除
    y = df['Class']
```

Python

文件(F) 编辑(E) 选择(S) 查看(V) 转到(G) 运行(R) ...

信用卡欺诈识别.ipynb

course7 > credit_card_fraud_recognition.ipynb > # 数据预处理与特征工程

生成 + 代码 + Markdown | 全部运行 | 重启 | 清除所有输出 | Jupyter 变量 | 大纲 ...

ML-course-env (Python 3.10.20)

```
# 划分训练集与测试集
X_train, X_test, y_train, y_test = train_test_split(
    X_resampled, y_resampled, test_size=0.2, random_state=42, stratify=y_resampled
)

print(f"\n训练集形状: {X_train.shape}, 测试集形状: {X_test.shape}")
print(f"\n训练集类别分布: {pd.Series(y_train).value_counts(normalize=True) * 100}")

return X_train, X_test, y_train, y_test, scaler, high_corr_features

# 执行预处理
X_train, X_test, y_train, y_test, scaler, selected_features = preprocess_and_feature_engineer(df)
```

Python

筛选后保留的特征 (共11个):

['V1', 'V3', 'V4', 'V7', 'V10', 'V11', 'V12', 'V14', 'V16', 'V17', 'V18']

训练集形状: (454984, 11), 测试集形状: (113726, 11)

训练集类别分布: Class

0 50.0

1 50.0

Name: proportion, dtype: float64

```
# 训练逻辑回归和K-近邻模型并调参
def train_models(X_train, y_train):
    # 逻辑回归调参
    lr_params = {'C': [0.001, 0.01, 0.1, 1, 10, 100]}
    lr = LogisticRegression(random_state=42, max_iter=1000)
    lr_grid = GridSearchCV(lr, lr_params, cv=5, scoring='f1', n_jobs=-1)
    lr_grid.fit(X_train, y_train)

    # K-近邻调参
    knn_params = {'n_neighbors': [3, 5, 7, 9, 11, 13, 15]}
    knn = KNeighborsClassifier(weights='distance') # 距离加权
    knn_grid = GridSearchCV(knn, knn_params, cv=5, scoring='f1', n_jobs=-1)
    knn_grid.fit(X_train, y_train)

    # 输出最优参数
    print("\n逻辑回归最优参数:", lr_grid.best_params_)
    print("\nK-近邻最优参数:", knn_grid.best_params_)

    return lr_grid.best_estimator_, knn_grid.best_estimator_

# 训练最优模型
lr_model, knn_model = train_models(X_train, y_train)
```

Python

```
# 训练逻辑回归和K-近邻模型并调参
def train_models(X_train, y_train):
    # 逻辑回归调参
    lr_params = {'C': [0.001, 0.01, 0.1, 1, 10, 100]}
    lr = LogisticRegression(random_state=42, max_iter=1000)
    lr_grid = GridSearchCV(lr, lr_params, cv=5, scoring='f1', n_jobs=-1)
    lr_grid.fit(X_train, y_train)

    # K-近邻调参
    knn_params = {'n_neighbors': [3, 5, 7, 9, 11, 13, 15]}
    knn = KNeighborsClassifier(weights='distance') # 距离加权
    knn_grid = GridSearchCV(knn, knn_params, cv=5, scoring='f1', n_jobs=-1)
    knn_grid.fit(X_train, y_train)

    # 输出最优参数
    print("\n逻辑回归最优参数:", lr_grid.best_params_)
    print("\nK-近邻最优参数:", knn_grid.best_params_)



    return lr_grid.best_estimator_, knn_grid.best_estimator_

# 训练最优模型
lr_model, knn_model = train_models(X_train, y_train)
```

Python


逻辑回归最优参数: {'C': 1}

K-近邻最优参数: {'n_neighbors': 3}



模型评估结果汇总:

	模型	准确率	精确率	召回率	F1-score	AUC-ROC
0	逻辑回归	0.9367	0.9721	0.8992	0.9343	0.9836
1	K-近邻	0.9990	0.9981	1.0000	0.9990	0.9995



```
import joblib

# 保存模型、标准化器和特征列表（用于新数据预测）
joblib.dump(lr_model, 'logistic_regression_fraud.pkl')
joblib.dump(knn_model, 'knn_fraud.pkl')
joblib.dump(scaler, 'scaler.pkl')
joblib.dump(selected_features, 'selected_features.pkl')

# 新数据预测
def predict_new_transaction(transaction_data):

    # 加载保存的组件
    scaler = joblib.load('scaler.pkl')
    selected_features = joblib.load('selected_features.pkl')
    model = joblib.load('logistic_regression_fraud.pkl')

    # 预处理新数据
    transaction_df = pd.DataFrame([transaction_data], columns=scaler.feature_names_in_)
    transaction_scaled = scaler.transform(transaction_df)
    transaction_selected = transaction_scaled[:, [list(scaler.feature_names_in_).index(f) for f in selected_features]]

    # 预测
    pred = model.predict(transaction_selected)[0]
    pred_proba = model.predict_proba(transaction_selected)[0][1]

    return f"交易预测结果: ('欺诈' if pred == 1 else '正常'), 欺诈概率: {pred_proba:.3f}"

# 测试新数据预测
new_transaction = np.random.randn(len(scaler.feature_names_in_))
print("\n新交易预测结果:")
print(predict_new_transaction(new_transaction))
```

[11]: 0.0s

新交易预测结果:
交易预测结果: 正常, 欺诈概率: 0.050

4. 数据分析

数据集共 284807 条样本、31 个特征（Time+V1-V28+Amount+Class），无任何缺失值，无需填充或删除样本；V1-V28 为脱敏标准化特征，均值接近 0，数值范围差异较小；Amount（交易金额）取值范围 0~25691.16 元，均值 88.35 元，标准差 250.12 元，数值跨度极大，需标准化处理；Time 为交易时间间隔（0~172792 秒），与欺诈行为无强相关性，后续剔除；存在严重类别不平衡——欺诈样本占比仅 0.173%，若直接建模，模型会偏向预测多数类（正常交易），导致欺诈漏判率极高，必须通过过采样等方法平衡数据分布。

5. 特征工程

通过逐列计算各特征与标签Class的皮尔逊相关系数，筛选相关性绝对值 > 0.1 的强相关特征；结果：保留 11 个核心特征，分别为['V1', 'V3', 'V4', 'V7', 'V10', 'V11', 'V12', 'V14', 'V16', 'V17', 'V18']；特征选择的目的是剔除冗余特征，降低模型复杂度，提升训练效率和泛化能力；使用 StandardScaler 对所有特征（V1-V28+Amount）进行标准化，目的是统一特征数值范围，避免 Amount 等数值跨度大的特征主导模型预测，同时适配逻辑回归（对尺度敏感）和 K - 近邻（依赖距离计算）的算法特性。

6. 模型建立与训练

数据划分比例为训练集 80%、测试集 20%；采用分层抽样（stratify=y_resampled），确保训练集和测试集类别分布一致（SMOTE 后均为 50% 正常、50% 欺诈）；最终数据规模为训练集 454904 条（11 维特征），测试集 113726 条（11 维特征）；

逻辑回归超参数搜索范围C=[0.001, 0.01, 0.1, 1, 10, 100]（正则化强度）；最优参数C=1（平衡模型偏差与方差，避免过拟合）；

KNN超参数搜索范围n_neighbors=[3, 5, 7, 9, 11, 13, 15]（近邻数量）；最优参数n_neighbors=3（3 近邻 + 距离加权weights='distance'，强化局部异常样本识别）；

采用 SMOTE 过采样，在欺诈样本特征空间插值生成新样本，将训练集类别分布平衡为 50%:50%，解决原始数据欺诈样本过少的问题。

7. 模型性能评估

针对类别不平衡特性，采用多维度指标组合，优先保证召回率（反欺诈核心需求）

- 召回率：衡量真实欺诈样本的识别能力（漏判率越低越好）；
- 精确率：衡量预测为欺诈的样本中真实欺诈的比例（误判率越低越好）；
- F1-score：平衡精确率与召回率，避免单一指标偏差；
- AUC-ROC：评估模型整体分类能力，越接近 1 性能越好；

结果分析

- 逻辑回归：准确率 93.67%，精确率 97.21%，召回率 89.92%，F1-score93.43%，AUC-ROC0.9836；存在 5729 个欺诈漏判，漏判率 10.08%；
- KNN：准确率 99.90%，精确率 99.81%，召回率 100%，F1-score99.90%，AUC-ROC0.9995；无欺诈漏判，仅 111 个正常交易误判（误判率 0.195%）；

结论：K - 近邻模型在反欺诈场景表现更优，完全满足 “零漏判” 核心需求，逻辑回归因线性特性无法捕捉复杂欺诈模式，存在明显漏判，不适合直接应用。

4 实验总结与讨论

1. 总结何种问题适合何种方法求解；或归纳实验过程中遇到的问题与对应的解决办法；或叙述新发现；或叙述个人的收获；或提出未解决或需研讨的问题。

（1）问题与方法的适配关系

类别极度不平衡的二分类任务（如信用卡反欺诈），且数据存在非线性关联时，适合采用 “SMOTE 过采样 + K - 近邻模型” 求解：SMOTE 能有效平衡训练集类别分布，避免模型偏向多数类，K - 近邻的非参数特性可捕捉特征间的非线性模式，结合距离加权能强化局部异常样本（欺诈）的识别能力，实现高召回率；而线性可分、对可解释性或实时性要求较高的二分类问题（如简单信用评分），更适合逻辑回归，其训练速度快、参数可解释，能快速输出预测结果并明确特征对结果的影响权重。

（2）实验过程中遇到的问题与解决办法

相关性计算维度不匹配（ValueError）：初始使用 `np.corrcoef` 拼接特征与标签时，矩阵维度与列名索引冲突，改用 `pandas` 逐列计算单个特征与标签的相关系数，彻底避免维度冲突；

KeyError（'Class' not in index）：合并特征与标签计算相关性后，筛选结果混入 Class 标签本身，通过仅遍历特征列、不合并标签列的方式，从根源上排除 Class 列的干扰；

AttributeError（'list' object has no attribute 'tolist'）：误对列表类型调用 `tolist`（）方法，直接删除多余方法调用，仅打印列表本身即可；

类别极度不平衡（欺诈样本占比 0.173%）：采用 SMOTE 过采样生成欺诈样本，结合模型 `class_weight` 参数调整，将训练集类别分布平衡为 50%:50%，解决模型偏向正常交易的问题；

特征冗余与尺度差异：通过相关性分析筛选强相关特征（保留 11 个核心特征），用 StandardScaler 标准化所有特征，统一数值范围，降低模型复杂度并提升训练效率。

（3）实验新发现

K - 近邻在高维数据（11 维）中仍能表现优异：传统认知中 K - 近邻易受高维数据影响，但通过特征选择剔除冗余后，3 近邻 + 距离加权的组合能精准捕捉欺诈样本的局部模式，实现 100% 召回率；

类别平衡对模型性能影响显著：原始不平衡数据直接建模会导致欺诈漏判率极高，经 SMOTE 处理后，两个模型的召回率均大幅提升，其中 K - 近邻实现零漏判；

反欺诈场景中指标优先级决定模型选择：准确率无法反映真实性能，召回率（避免欺诈漏判）是核心指标，K - 近邻虽准确率略高，但零漏判的特性使其远超逻辑回归，更适合实际应用；

逻辑回归的线性局限性不可忽视：即使调整正则化参数和类别权重，逻辑回归仍因无法拟合欺诈样本的非线性模式，存在 10.08% 的漏判率，难以满足反欺诈的严格需求。

（4）个人收获

掌握了类别不平衡二分类任务的完整处理流程：从数据探索（识别类别不平衡、特征分布问题），到预处理（标准化、特征选择），再到不平衡处理（SMOTE 过采样）、模型训练与调参，最后通过多维度指标（精确率、召回率、F1-score、AUC-ROC）评估模型，形成闭环；

明确了不同模型的适用边界：线性模型（逻辑回归）适合简单线性关系、可解释性需求场景，非参数模型（K - 近邻）适合非线性数据、高准确率需求场景，需根据任务特性选择；

提升了代码调试与问题排查能力：针对维度不匹配、索引错误等常见问题，学会从数据结构、方法调用逻辑入手定位原因，通过简化代码逻辑、替换计算方式等手段高效解决；

理解了业务场景对模型评估的影响：反欺诈场景中“漏判损失远大于误判损失”，需优先保证召回率，而非单一追求准确率，建立了“业务需求决定评估指标优先级”的思维。

（5）未解决或需研讨的问题

数据泄露问题：当前流程先进行 SMOTE 过采样再划分训练 / 测试集，导致测试集包含过采样生成的样本信息，评估结果虚高，需研讨“先划分数据集、仅对训练集过采样”的修正方案及对结果的影响；

K - 近邻的实时性问题：K - 近邻为惰性学习模型，推理速度随数据量增长线性下降，如何在保证高召回率的前提下，通过近似最近邻算法（如 FAISS）或模型优化提升实时性，适配实际反欺诈场景的实时检测需求；

SMOTE 过采样的样本真实性：生成的插值样本并非真实交易数据，可能引入噪声，需研讨如何通过结合真实业务规则约束过采样过程，或采用“过采样 + 欠采样”混合策略，平衡样本真实性与类别平衡性；

匿名特征的可解释性局限：V1-V28 为脱敏特征，无法结合交易地点、商户类型等业务知识优化特征工程，如何在保护数据隐私的同时，引入有效业务特征提升模型可解释性与泛化能力；

模型泛化能力验证：当前测试集为平衡分布，未使用真实场景中“正常交易占绝对多数”的数据集验证模型，需研讨如何设计更贴合真实场景的测试方案，准确评估模型在实际应用中的表现。

2. 讨论最终得到的结果是否合理、是否达到题目要求； 分析可能的问题例如误差过大或效果不佳，分析产生的原因，探讨可能的解决方法。

（1）结果合理性与题目要求达成情况

最终实验结果整体合理且完全达到题目要求。从合理性来看，K - 近邻模型实现 100% 召回率、99.81% 精确率及 0.9995 的 AUC-ROC，这一表现契合数据特性：SMOTE 过采样平衡类别分布后，3 近邻 + 距离加权的组合能精准捕捉欺诈样本的局部非线性模式，而非参数模型的特性使其无需假设数据分布，自然适配欺诈交易与正常交易间的复杂关联；逻辑回归作为线性模型，89.92% 的召回率和 0.9836 的 AUC-ROC 也符合其算法边界，线性模型难以拟合高维数据中的非线性欺诈模式，出现一定漏判属于合理范畴。从题目要求来看，任务核心是 “提前发现信用卡盗刷事件，准确预测新交易是否为盗刷”，K - 近邻模型实现零欺诈漏判，完全满足反欺诈场景 “避免漏判导致经济损失” 的核心需求；逻辑回归虽存在 10.08% 的漏判率，但整体分类能力优异，也达到了 “构建简单反欺诈预测模型” 的基础要求，两者均完成了数据预处理、特征工程、建模训练与评估的全流程任务。

（2）可能的问题、产生原因及解决方法

数据泄露导致模型评估结果虚高：这是本次实验最核心的潜在问题，表现为 K - 近邻的极致性能可能受测试集信息泄露影响。产生原因是实验流程中先对全量数据进行 SMOTE 过采样，再划分训练集与测试集，导致测试集包含了基于训练集生成的插值样本，相当于模型在训练过程中间接 “见过” 测试集相关信息，评估结果无法反映真实泛化能力。解决方法是调整流程顺序，先按 8:2 比例划分训练集与测试集，仅对训练集执行 SMOTE 过采样平衡类别分布，测试集保持原始真实的类别不平衡状态，确保评估结果能真实反映模型在实际场景中的表现。

KNN模型实时性不足，难以适配实际部署场景：表现为随着数据量增长，模型推理速度会显著下降。产生原因是 K - 近邻属于惰性学习，无显式训练过程，推理时需计算测试样本与所有训练样本的距离，数据量越大计算成本越高，而信用卡交易具有实时性要求，该模型难以满足线上实时检测需求。解决方法包括两种路径：一是优化现有模型，采用近似最近邻（ANN）算法（如 FAISS、Annoy）替代传统距离计算，通过牺牲少量精度换取大幅提升的推理速度；二是替换模型，选用 XGBoost、LightGBM 等集成学习模型，这类模型兼具高召回率与快速推理能力，能在保证性能的同时满足实时性要求。

SMOTE 过采样引入噪声样本，可能影响模型泛化能力：表现为模型在真实场景中可能对部分边界案例判断失误。产生原因是 SMOTE 通过在少数类样本特征空间中随机插值生成新样本，这些插值样本并非真实交易数据，可能脱离实际业务逻辑，引入与真实欺诈模式不符的噪声。解决方法是优化采样策略，采用 “SMOTE 过采样 + NearMiss 欠采样” 的混合采样方式，在平衡类别的同时减少噪声；或在过采样过程中加入业务约束，例如基于交易金额、时间间隔等合理范围限制插值样本的特征取值，确保生成样本符合真实交易规律。

逻辑回归模型漏判率较高，线性拟合能力不足：表现为 10.08% 的欺诈漏判率，难以满足高安全性需求。产生原因是逻辑回归作为线性模型，无法捕捉欺诈样本与特征间的非线性关联，而信用卡欺诈行为往往涉及多特征的复杂交互（如特定金额区间 + 短时间高频交易），线性模型无法有效拟合这类模式。解决方法包括两方面：一是优化特征工程，引入特征交互项（如 V1V4、V10V17），将非线性关系转化为线性可识别的特征；二是替换为非线性模型，如随机森林、梯度提升树等，这类模型能自动学习特征间的复杂关联，在保持一定可解释性的同时提升欺诈识别能力。

匿名特征限制模型可解释性，不利于业务落地：表现为模型仅能输出预测结果，无法解释 “为何判定该交易为欺诈”，难以通过业务审核与用户沟通。产生原因是数据集的 V1-V28 为脱敏匿名特征，缺乏交易地点、商户类型、用户历史行为等业务属性，无法结合实际场景构建可解释的特征。解决方法

是在数据隐私保护的前提下，引入合规的业务特征，例如基于交易时间构建 “是否夜间交易” 特征、基于商户代码构建 “商户风险等级” 特征，通过业务可理解的特征提升模型可解释性，同时进一步优化模型性能。