

实验报告

课程:机器学习	实验名称:降维算法	日期:5.25
姓名:雷文豪	学号:138022024031	专业班级:人工智能

1 实验目的

1. 掌握降维算法的原理，使用降维算法求解问题。
2. 学习解题设计、通过代码编写与运行实施解题、完成程序正确性的验证。

2 实验内容提要 with 实验设备

1. 给待解问题设计求解方法。
2. 对给定数据集，设计适合的求解方法、编写程序实施求解。
3. 实验结果的分析与确认。
4. 实验设备：个人电脑或便携式电脑，并安装 Windows 等操作系统和编程开发环境。

3 实验内容与步骤

3.1 降维分析问题（模仿实例例题求解）

参考课本的实例例题，对主成分分析的算法流程进行编程实现。然后，对鸢尾花（Iris）数据集，将其转换为主成分的数据，并确定主成分的数量。

1. 简单写出你的求解设计（例如：主成分分析的简单原理、如何选取主成分）。
2. 获得的结果，即选取多少主成分、包含原始数据的多少信息量。
3. 程序运行成功的截图（包含源文件名<字母+学号后3位>、运行光标在程序尾行）。

一、求解设计

1. 主成分分析(PCA)核心原理：

PCA是一种线性降维方法，通过对原始特征进行正交变换，将数据投影到方差最大的方向（即主成分方向），从而实现降维的同时尽可能保留原始数据的信息。

2. PCA算法流程:

- (1) **数据标准化:** 对每个特征计算 $z\text{-score} = (x - \mu) / \sigma$, 使所有特征在同一尺度
- (2) **计算协方差矩阵:** $C = (X^T \cdot X) / n$, 衡量各特征间的线性相关性
- (3) **特征值分解:** 对协方差矩阵进行特征值分解, 得到特征值 λ 和特征向量 v
- (4) **排序:** 按特征值从大到小排列对应的特征向量, 特征值越大 = 该方向方差越大
- (5) **选取主成分:** 选取前k个特征向量组成投影矩阵, k为主成分数目

3. 主成分数量的确定方法:

- (1) **累计方差贡献率法:** 选取累计贡献率达到 85%~95% 的最少主成分数
- (2) **Kaiser准则:** 选取特征值大于1的主成分 (适用于标准化后数据, 均值特征值=1)
- (3) **碎石图观察法:** 在Scree Plot上观察特征值曲线的“拐点”

二、结果分析

1. 结果

➤ Iris数据集基本信息:

- 样本数: 150, 特征数: 4
- 特征: 花萼长度, 花萼宽度, 花瓣长度, 花瓣宽度
- 类别: setosa(50), versicolor(50), virginica(50)

➤ 各主成分分析结果:

PC1: 特征值 = 2.8990, 方差贡献率 = 72.96%

PC2: 特征值 = 0.9079, 方差贡献率 = 22.85%

PC3: 特征值 = 0.1458, 方差贡献率 = 3.67%

PC4: 特征值 = 0.0206, 方差贡献率 = 0.52%

➤ 累计方差贡献率:

前1个主成分: 72.96%

前2个主成分: 95.81%

前3个主成分: 99.48%

前4个主成分: 100.00%

➤ 主成分载荷 (原始特征在主成分上的权重):

PC1: sepal_length=-0.5211, sepal_width=+0.3774, petal_length=+0.7196, petal_width=+0.2613



PC2: sepal_length=+0.2693, sepal_width=+0.9233, petal_length=-0.2444, petal_width=-0.1235

PC3: sepal_length=-0.5804, sepal_width=+0.0245, petal_length=-0.1421, petal_width=-0.8014

PC4: sepal_length=-0.5649, sepal_width=+0.0669, petal_length=-0.6343, petal_width=+0.5236

2. 分析

- 主成分个数：选取 2 个主成分。理由：前2个主成分的累计方差贡献率为 95.81%，超过85%常用阈值，能够代表原始数据绝大部分信息。
- Kaiser准则下只有PC1特征值>1，但仅保留72.96%的信息可能不够充分，因此采用累计贡献率准则选择2个主成分更合适。
- PC1主要反映花瓣长度(0.7196)和花萼长度(-0.5211)，即花的大小维度；PC2主要反映花萼宽度(0.9233)，即花的形状维度。
- 从2D主成分散点图可以看出，setosa类别与另两类在PC1方向上即能较好地分离，versicolor和virginica在PC1+PC2组合下有较好的区分度。



三、运行截图

```
task3_1.py
148 for i in range(4):
149     print(f" PC{i+1}: ", end="")
150     for j, name in enumerate(feature_names):
151         print(f"{name}={pca.components_[i, j]:+.4f} ", end="")
152     print()
153
154 print("\n" + "=" * 60)
155 print("分析完成。选取前2个主成分,累计贡献率{:.2f}%。".format(cumsum[1]*100))
156
```

(machine_learning_env) PS D:\Studies\机器学习\src\ch11> python task3_1.py

PC1: 特征值=2.8990, 方差贡献率=0.7296 (72.96%)
PC2: 特征值=0.9079, 方差贡献率=0.2285 (22.85%)
PC3: 特征值=0.1458, 方差贡献率=0.0367 (3.67%)
PC4: 特征值=0.0206, 方差贡献率=0.0052 (0.52%)

前1个主成分累计方差贡献率: 72.96%
前2个主成分累计方差贡献率: 95.81%
前3个主成分累计方差贡献率: 99.48%
前4个主成分累计方差贡献率: 100.00%

=====

主成分数量确定:
累计贡献率>85.0%需要: 2 个主成分 (累计95.81%)
Kaiser准则(特征值>1)建议: 1 个主成分

结论: 选取 2 个主成分即可代表原始数据的主要信息, 累计方差贡献率 = 95.81%

=====

主成分载荷 (各原始特征在主成分上的权重):

	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)
PC1:	-0.5211	+0.3774	+0.7196	+0.2613
PC2:	+0.2693	+0.9233	-0.2444	-0.1235
PC3:	-0.5804	+0.0245	-0.1421	-0.8014
PC4:	-0.5649	+0.0669	-0.6343	+0.5236

=====

分析完成。选取前2个主成分,累计贡献率95.81%。

3.2 数据降维与可视化（模仿实例例题求解）

参考课本的实例例题，采用主成分分析方法，对小麦种子（seeds.txt）数据集进行降维分析，并在主成分坐标系可视化降维结果（即3类样本在二维主成分坐标系的数据散点图）。

1. 简单写出你的求解设计（例如：如何处理原始数据、主成分分析的简单原理、如何选取主成分、如何可视化）。
2. 获得的结果，即选取多少主成分、包含原始数据的多少信息量。
3. 程序运行成功的截图（包含源文件名<字母+学号后3位>、运行光标在程序尾行）。

一、求解设计

1. 数据处理方法：

- (1) 读取seeds.txt数据文件（制表符分隔，7个特征+1个类别标签）
- (2) 使用z-score标准化：对每个特征计算 $(x - \mu) / \sigma$ ，消除量纲影响
- (3) 共210个样本，3个类别（Kama小麦、Rosa小麦、Canadian小麦各70个）

2. PCA算法流程：

- (1) 数据标准化（零均值、单位方差）
- (2) 计算协方差矩阵 $C = X^T \cdot X / n$
- (3) 对协方差矩阵进行特征值分解
- (4) 按特征值降序排列特征向量（即主成分方向）
- (5) 选取前k个主成分进行投影变换

3. 主成分选取准则：

- (1) 累计方差贡献率 $\geq 85\%$ → 选择2个主成分（累计88.98%）
- (2) Kaiser准则（特征值 > 1 ）→ 选择2个主成分（PC1=5.01, PC2=1.19）
- (3) 综合考虑，选择2个主成分用于二维可视化

4. 可视化方法：

将标准化后的数据投影到前2个主成分方向，以散点图展示，
不同类别使用不同颜色和标记区分。

二、结果分析

1. 结果

Seeds(小麦种子)数据集基本信息：

- 样本数: 210, 特征数: 7, 类别数: 3
- 特征: Area(面积), Perimeter(周长), Compactness(紧密度),
Kernel Length(核长度), Kernel Width(核宽度),
Asymmetry Coef(不对称系数), Groove Length(沟槽长度)

- 类别分布: Kama=70, Rosa=70, Canadian=70

标准化前数据统计:

均值: [14.8475, 14.5593, 0.8710, 5.6285, 3.2586, 3.7002, 5.4081]

标准差: [2.9097, 1.3060, 0.0236, 0.4431, 0.3777, 1.5036, 0.4915]

(原始特征量纲差异较大, 如Area均值为14.85, Compactness仅0.87, 标准化是必要的)

各主成分分析结果:

PC1: 特征值 = 5.0072, 方差贡献率 = 71.87%

PC2: 特征值 = 1.1919, 方差贡献率 = 17.11%

PC3: 特征值 = 0.6748, 方差贡献率 = 9.69%

PC4: 特征值 = 0.0680, 方差贡献率 = 0.98%

PC5: 特征值 = 0.0186, 方差贡献率 = 0.27%

PC6: 特征值 = 0.0053, 方差贡献率 = 0.08%

PC7: 特征值 = 0.0008, 方差贡献率 = 0.01%

累计方差贡献率:

前1个主成分: 71.87%

前2个主成分: 88.98%

前3个主成分: 98.67%

前4个主成分: 99.64%

前5个主成分: 99.91%

前6个主成分: 99.99%

前7个主成分: 100.00%

主成分数量确定:

- 累计贡献率 $\geq 80\%$: 需要 2 个主成分 (累计88.98%)

- 累计贡献率 $\geq 85\%$: 需要 2 个主成分 (累计88.98%)

- 累计贡献率 $\geq 90\%$: 需要 3 个主成分 (累计98.67%)

- 累计贡献率 $\geq 95\%$: 需要 3 个主成分 (累计98.67%)

- Kaiser准则: 2 个主成分

结论: 选取 2 个主成分, 累计方差贡献率 = 88.98%

前3个主成分载荷 (特征 $\rightarrow$ 主成分的权重):

PC1: Area=-0.4445, Perimeter=+0.0266, Compactness=+0.0259,

Kernel_Length=-0.1936, Kernel_Width=+0.2044,

Asymmetry_Coef=-0.4264, Groove_Length=-0.7348

PC2: Area=-0.4416, Perimeter=+0.0840, Compactness=-0.0598,

Kernel_Length=-0.2955, Kernel_Width=+0.1743,

Asymmetry_Coef=-0.4762, Groove_Length=+0.6708

PC3: Area=-0.2770, Perimeter=-0.5292, Compactness=+0.6297,

Kernel_Length=+0.3328, Kernel_Width=-0.3327,

Asymmetry_Coef=-0.1416, Groove_Length=+0.0726

2. 分析

1. PC1（解释71.87%方差）主要反映Groove Length(沟槽长度)和Area(面积)的综合指标，代表了种子的"大小"维度。


2. PC2（解释17.11%方差）主要反映Groove Length(沟槽长度，正向)和Asymmetry Coef(不对称系数，负向)的对比，代表了种子的"形状对称性"维度。

3. 二维主成分散点图中，3类小麦种子呈现较明显的聚类分布：

- Kama和Rosa两类在PC1-PC2空间中有一定重叠

- Canadian类别相对更容易区分

4. 仅用2个主成分（损失约11%信息），即可在二维平面上有效展示3类样本的整体分布格局，满足可视化分析的需求。



三、运行截图

```
task3_2.py X
task3_2.py > ...
158 for i in range(3):
159     print(f" PC{i+1}: ", end="")
160     for j, name in enumerate(feature_names):
161         print(f"{name}={pca.components_[i, j]:.4f} ", end="")
162     print()
163
164 print("\n" + "=" * 60)
165 print("分析完成。选取前2个主成分可视化,累计贡献率{:.2f}%。".format(cumsum[1]*100))
166

问题 输出 终端 调试控制台 窗口
(machine_learning_env) PS D:\Studies\机器学习\src\ch11> python task3_2.py

前1个主成分累计方差贡献率: 71.87%
前2个主成分累计方差贡献率: 88.98%
前3个主成分累计方差贡献率: 98.67%
前4个主成分累计方差贡献率: 99.64%
前5个主成分累计方差贡献率: 99.91%
前6个主成分累计方差贡献率: 99.99%
前7个主成分累计方差贡献率: 100.00%

主成分数量确定:
累计贡献率>80.0%: 需要 2 个主成分 (累计88.98%)
累计贡献率>85.0%: 需要 2 个主成分 (累计88.98%)
累计贡献率>90.0%: 需要 3 个主成分 (累计98.67%)
累计贡献率>95.0%: 需要 3 个主成分 (累计98.67%)
Kaiser准则(特征值>1): 2 个主成分

结论: 选取 2 个主成分,累计方差贡献率 = 88.98%, 足以在可视化中有效展示3类种子的分布。

前3个主成分载荷 (原始特征在主成分上的权重):
PC1: Area=-0.4445 Perimeter=-0.0266 Compactness=+0.0259 Kernel Length=-0.1936 Kernel Width=+0.2044 Asymmetry Coef=-0.4264 Groove Length=+0.7348
PC2: Area=-0.4416 Perimeter=-0.0840 Compactness=-0.0598 Kernel Length=-0.2955 Kernel Width=+0.1743 Asymmetry Coef=-0.4762 Groove Length=-0.6708
PC3: Area=-0.2770 Perimeter=+0.5292 Compactness=+0.6297 Kernel Length=+0.3328 Kernel Width=-0.3327 Asymmetry Coef=-0.1416 Groove Length=-0.0726

分析完成。选取前2个主成分可视化,累计贡献率88.98%。
(machine_learning_env) PS D:\Studies\机器学习\src\ch11>
```

3.3 三维主成分空间数据散点图（独立求解问题）

对上题进行更多讨论：选取最少几个主成分能保留原始数据足够多的信息量？若你选取的主成分数量多于 2 个，请将主成分数据在三维空间进行可视化，并尝试给出三维主成分坐标系的数据散点图，使得 3 类样本之间展示的可区分性最好。

1. 主成分数量与信息量讨论。
2. 编程实现设计，全部代码（非图片）写到下面（添加必要的注释说明）。
3. 获得的结果，即 3 类样本在三维主成分坐标系的数据散点图。
4. 程序运行成功的截图（包含源文件名< 字母 + 学号后 3 位>、运行光标在程序尾行）。

一、主成分数量与信息量讨论

对seeds数据集（7个特征、210个样本、3类），PCA分析结果如下：

各主成分贡献：

PC1: 特征值=5.0072, 贡献率=71.87%, 累计=71.87%

PC2: 特征值=1.1919, 贡献率=17.11%, 累计=88.98%

PC3: 特征值=0.6748, 贡献率= 9.69%, 累计=98.67%

PC4: 特征值=0.0680, 贡献率= 0.98%, 累计=99.64%

PC5: 特征值=0.0186, 贡献率= 0.27%, 累计=99.91%

PC6: 特征值=0.0053, 贡献率= 0.08%, 累计=99.99%

PC7: 特征值=0.0008, 贡献率= 0.01%, 累计=100.00%

主成分数量选择讨论：

1. 信息保留阈值分析

- 保留 $\geq 80\%$ 信息：2个主成分即可（累计 88.98%）

优势：可降维至二维平面，便于可视化观察

不足：损失约11%的原始数据信息

- 保留 $\geq 90\%$ 信息：需要3个主成分（累计 98.67%）

优势：信息保留极为充分（接近99%），损失可忽略不计

不足：需要三维空间展示，观察角度需选择

- 保留 $\geq 95\%$ 信息：同样需要3个主成分

因为从第4个主成分开始贡献率仅0.98%，增加维度收益极低

2. Kaiser准则（特征值 > 1 ）

标准化数据的平均特征值为1。只有PC1(5.007)和PC2(1.192)满足条件。

PC3(0.675) < 1 ，按此准则仅选2个主成分。

但Kaiser准则偏保守，可能丢失有意义的信息维度。

3. 碎石图拐点分析

特征值变化趋势：5.01 $\rightarrow$ 1.19 $\rightarrow$ 0.67 $\rightarrow$ 0.07 $\rightarrow$...

PC3 $\rightarrow$ PC4出现明显的"肘部"拐点（从0.67骤降至0.07），

说明前3个主成分包含了大部分结构信息，第4个开始为噪声。

拐点法建议：保留3个主成分。

4. 最终决策

综合考虑：

- 二维方案：2个PC，累计贡献率88.98%，满足基本可视化需求

- 三维方案：3个PC，累计贡献率98.67%，几乎完整保留原始信息

本实验选取 3 个主成分。虽然Kaiser准则仅支持2个，但拐点分析和

累计贡献率均指向3个。第3个主成分贡献9.69%，包含了Compactness

和Perimeter等结构信息，对区分Canadian类别可能有重要意义。

二、求解设计与代码实现

1. 采用与任务3.2完全一致的从底层实现的PCA算法
2. 使用z-score标准化处理原始数据（消除量纲差异）
3. 提取前3个主成分，在三维空间中绘制散点图
4. 提供3个不同视角的三维图，帮助从各角度观察类别分离情况：
 - 视角1：默认角度(elev=25, azim=-60)，兼顾三个维度的观察
 - 视角2：俯视角度(elev=60, azim=-30)，侧重PC1-PC2平面
 - 视角3：侧面角度(elev=10, azim=-120)，侧重PC2-PC3平面
5. 额外提供三个二维投影面(PC1-PC2, PC1-PC3, PC2-PC3)的散点图

源代码：

"""

实验3.3 — 三维主成分空间数据散点图（独立求解问题）

讨论主成分数量与信息量的关系，对seeds数据集进行三维PCA可视化

使得3类样本之间展示的可区分性最好

"""

```
import numpy as np
```

```
import matplotlib.pyplot as plt
```

```
from mpl_toolkits.mplot3d import Axes3D
```

```
# ===== 1. PCA类定义（底层实现） =====
```

```
class PCA:
```

```
    def __init__(self, n_components=None):
```

```
        self.n_components = n_components
```

```
        self.components_ = None
```

```
        self.explained_variance_ = None
```

```
        self.explained_variance_ratio_ = None
```

```
        self.mean_ = None
```

```

def fit(self, X):

    self.mean_ = np.mean(X, axis=0)

    X_centered = X - self.mean_

    n = X_centered.shape[0]

    cov_matrix = np.dot(X_centered.T, X_centered) / n

    eigenvalues, eigenvectors = np.linalg.eigh(cov_matrix)

    idx = np.argsort(eigenvalues)[::-1]

    eigenvalues = eigenvalues[idx]

    eigenvectors = eigenvectors[:, idx]

    self.explained_variance_ = eigenvalues

    total_var = np.sum(eigenvalues)

    self.explained_variance_ratio_ = eigenvalues / total_var

    if self.n_components is not None:

        self.components_ = eigenvectors[:, :self.n_components]

    else:

        self.components_ = eigenvectors

    return self

```

```

def transform(self, X):

    X_centered = X - self.mean_

    return np.dot(X_centered, self.components_)

```

```

def fit_transform(self, X):

    self.fit(X)

    return self.transform(X)

```

===== 2. 加载数据并标准化 =====

```

data_rows = []

with open('seeds.txt', 'r') as f:

    for line in f:

        parts = line.strip().split()

        if len(parts) == 8:

```

```

        data_rows.append([float(x) for x in parts])

data = np.array(data_rows)

X = data[:, :-1]

y = data[:, -1].astype(int)


feature_names = [

    'Area', 'Perimeter', 'Compactness',

    'Kernel Length', 'Kernel Width', 'Asymmetry Coef', 'Groove Length'

]

class_names = {1: 'Kama', 2: 'Rosa', 3: 'Canadian'}


# z-score标准化

X_mean = np.mean(X, axis=0)

X_std = np.std(X, axis=0, ddof=1)

X_stdized = (X - X_mean) / X_std


# ===== 3. PCA分析 =====

pca = PCA()

X_pca = pca.fit_transform(X_stdized)

cumsum = np.cumsum(pca.explained_variance_ratio_)


print("=" * 65)

print("主成分数量与信息量讨论")

print("=" * 65)

print(f"\n{'PC编号':<8}{'特征值':<12}{'贡献率':<12}{'累计贡献率':<14}")

print("-" * 46)

for i in range(7):

    print(f" PC{i+1:<5} {pca.explained_variance_ratio_[i]:<12.4f}"

          f"{pca.explained_variance_ratio_[i]*100:<10.2f}%"

          f" {cumsum[i]*100:<10.2f}%")


print("\n" + "-" * 65)

print("主成分数量选取讨论:")

```

```
print("-" * 65)
```

```
print("""
```

1. 常用信息保留阈值分析：

- 若要求保留原始数据 $\geq 80\%$ 的信息：需要 2 个主成分（累计 88.98%）

优点：可将7维数据降至2维，便于平面可视化

缺点：损失约11%的信息，部分细节可能丢失

- 若要求保留原始数据 $\geq 90\%$ 的信息：需要 3 个主成分（累计 98.67%）

优点：保留了绝大部分原始信息（近99%），信息损失极小

缺点：需三维可视化，观察略复杂

- 若要求保留原始数据 $\geq 95\%$ 的信息：需要 3 个主成分（累计 98.67%）

与 $\geq 90\%$ 阈值结论相同，因为PC4贡献率仅0.98%

2. Kaiser准则（特征值 > 1 ）：

标准化后数据的平均特征值为1，准则建议保留特征值 >1 的主成分。

PC1=5.007 > 1 , PC2=1.192 > 1 , PC3=0.675 < 1

→ 建议保留 2 个主成分

3. 碎石图拐点分析：

PC1→PC2 特征值骤降（5.01→1.19），PC2→PC3 缓慢下降（1.19→0.67），

PC3→PC4 再次骤降（0.67→0.07）。真正的"肘部"在PC3处。

→ 拐点法建议保留 3 个主成分

4. 最终决策：

综合考虑信息保留充分性和可视化可行性：

- 二维可视化：保留2个PC（88.98%），满足基本观察需求

- 三维可视化：保留3个PC（98.67%），信息几乎完整保留

本实验选取 3 个主成分进行三维可视化，在三维主成分空间中

展示3类小麦种子的分布，以获得最佳的可区分性。

```
""")
```

```
# ===== 4. 高质量三维散点图 =====
```

```
fig = plt.figure(figsize=(16, 6))
```

```
# ---- (a) 三维散点图：最佳视角 ----
```

```
ax1 = fig.add_subplot(1, 3, 1, projection='3d')
```

```
colors = ['#1f77b4', '#ff7f0e', '#2ca02c']
```

```
markers = ['o', '^', 's']
```

```
for c, color, marker in zip(sorted(class_names.keys()), colors, markers):
```

```
    mask = y == c
```

```
    ax1.scatter(X_pca[mask, 0], X_pca[mask, 1], X_pca[mask, 2],
```

```
                c=color, marker=marker, label=class_names[c],
```

```
                alpha=0.8, edgecolors='k', linewidth=0.4, s=45)
```

```
ax1.set_xlabel(f'PC1 ({pca.explained_variance_ratio_[0]*100:.1f}%)')
```

```
ax1.set_ylabel(f'PC2 ({pca.explained_variance_ratio_[1]*100:.1f}%)')
```

```
ax1.set_zlabel(f'PC3 ({pca.explained_variance_ratio_[2]*100:.1f}%)')
```

```
ax1.set_title('View 1: Default Angle', fontsize=12)
```

```
ax1.legend(fontsize=9, loc='upper left')
```

```
ax1.view_init(elev=25, azim=-60)
```

```
# ---- (b) 三维散点图：俯视角度 ----
```

```
ax2 = fig.add_subplot(1, 3, 2, projection='3d')
```

```
for c, color, marker in zip(sorted(class_names.keys()), colors, markers):
```

```
    mask = y == c
```

```
    ax2.scatter(X_pca[mask, 0], X_pca[mask, 1], X_pca[mask, 2],
```

```
                c=color, marker=marker, label=class_names[c],
```

```
                alpha=0.8, edgecolors='k', linewidth=0.4, s=45)
```

```
ax2.set_xlabel(f'PC1 ({pca.explained_variance_ratio_[0]*100:.1f}%)')
```

```
ax2.set_ylabel(f'PC2 ({pca.explained_variance_ratio_[1]*100:.1f}%)')
```

```

ax2.set_xlabel(f'PC3 ({pca.explained_variance_ratio_[2]*100:.1f}%)')
ax2.set_title('View 2: Top-down Angle', fontsize=12)
ax2.legend(fontsize=9, loc='upper left')
ax2.view_init(elev=60, azim=-30)

```

---- (c) 三维散点图：侧面视角 ----

```

ax3 = fig.add_subplot(1, 3, 3, projection='3d')
for c, color, marker in zip(sorted(class_names.keys()), colors, markers):
    mask = y == c
    ax3.scatter(X_pca[mask, 0], X_pca[mask, 1], X_pca[mask, 2],
                c=color, marker=marker, label=class_names[c],
                alpha=0.8, edgecolors='k', linewidth=0.4, s=45)

```

```

ax3.set_xlabel(f'PC1 ({pca.explained_variance_ratio_[0]*100:.1f}%)')
ax3.set_ylabel(f'PC2 ({pca.explained_variance_ratio_[1]*100:.1f}%)')
ax3.set_zlabel(f'PC3 ({pca.explained_variance_ratio_[2]*100:.1f}%)')
ax3.set_title('View 3: Side Angle', fontsize=12)
ax3.legend(fontsize=9, loc='upper left')
ax3.view_init(elev=10, azim=-120)

```

```

plt.suptitle('Wheat Seeds — 3D PCA Visualization (First 3 PCs, Cumulative = 98.67%)',
            fontsize=14, y=1.02)
plt.tight_layout()
plt.savefig('task3_3_fig_3views.png', dpi=150, bbox_inches='tight')
plt.show()

```

===== 5. 补充：三个二维投影面 =====

```

fig2, axes2 = plt.subplots(1, 3, figsize=(16, 5))

```

```

pairs = [(0, 1), (0, 2), (1, 2)]

```

```

titles = [
    f'PC1 vs PC2 ({cumsum[1]*100:.1f}% cum.)',

```

```

f'PC1 vs PC3 ({pca.explained_variance_ratio_[0]*100+pca.explained_variance_ratio_[2]*100:.1f}%
cum.)',
f'PC2 vs PC3 ({pca.explained_variance_ratio_[1]*100+pca.explained_variance_ratio_[2]*100:.1f}%
cum.)'
]

```

```

for ax, (i, j), title in zip(axes2, pairs, titles):
    for c, color, marker in zip(sorted(class_names.keys()), colors, markers):
        mask = y == c
        ax.scatter(X_pca[mask, i], X_pca[mask, j],
                    c=color, marker=marker, label=class_names[c],
                    alpha=0.75, edgecolors='k', linewidth=0.5, s=45)
    ax.set_xlabel(f'PC{i+1}', fontsize=11)
    ax.set_ylabel(f'PC{j+1}', fontsize=11)
    ax.set_title(title, fontsize=12)
    ax.legend(fontsize=9)
    ax.grid(True, alpha=0.3)

```

```

plt.suptitle('Pairwise 2D Projections of First 3 Principal Components',
             fontsize=14, y=1.02)
plt.tight_layout()
plt.savefig('task3_3_fig_projections.png', dpi=150, bbox_inches='tight')
plt.show()

```

```

# ===== 6. 主成分载荷详细分析 =====

print("\n" + "=" * 65)

print("前3个主成分载荷详细分析")

print("=" * 65)

for i in range(3):

    print(f"\n PC{i+1} (贡献率: {pca.explained_variance_ratio_[i]*100:.2f}%):")

    loadings = pca.components_[i]

    sorted_idx = np.argsort(np.abs(loadings))[:-1]

    for rank, j in enumerate(sorted_idx):

```



```
direction = "+" if loadings[j] > 0 else "-"
```

```
print(f" {rank+1}. {feature_names[j]:<16s} [{direction}] {loadings[j]:+.4f}")
```


```
print("\n" + "=" * 65)
```

```
print("分析完成。3个主成分累计贡献率98.67%，三维可视化可清晰区分3类种子。")
```


三、结果分析

- PC1 (71.87%): 主要反映Groove_Length(-0.73)和Area(-0.44)、Asymmetry_Coef(-0.43)的综合指标→ "种子整体大小与沟槽特征因子"
- PC2 (17.11%): 主要反映Groove_Length(+0.67)与Asymmetry_Coef(-0.48)、Area(-0.44)的对比关系→ "沟槽长度与不对称性的对比因子"
- PC3 (9.69%): 主要反映Compactness(+0.63)与Perimeter(-0.53)的对比、Kernel_Length(+0.33)与Kernel_Width(-0.33)的对比→ "种子形状紧密度因子"
- 生成的可视化图表:
 1. task3_3_fig_3views.png — 三个不同视角的三维主成分散点图
 2. task3_3_fig_projections.png — 三个二维投影面的散点图
- 从三维散点图观察:
 - 在PC1-PC2-PC3三维空间中，3类小麦种子呈现较清晰的聚类结构
 - Kama(蓝色圆点)和Rosa(橙色三角)在PC1-PC2平面上有一定重叠，但在加入PC3维度后，两者在三维空间中分离度提高
 - Canadian(绿色方块)在PC1方向上即与其他两类有较好的分离，分布更加集中，可区分性最强
 - 三维可视化相比二维能展示更丰富的类别间关系，增强了对数据结构的理解
- 虽然2D可视化足够展示数据的主要分布模式，但3D可视化在几乎不增加信息损失的前提下显著提升了类别间细微差异的呈现能力。对于本数据集，选取3个主成分是最优选择。

Wheat Seeds — 3D PCA Visualization (First 3 PCs, Cumulative = 98.67%)



Pairwise 2D Projections of First 3 Principal Components



四、运行截图

```
task3_3.py
loadings = pca.components_[1:]
sorted_idx = np.argsort(np.abs(loadings))[:,1]
for rank, j in enumerate(sorted_idx):
    direction = "+" if loadings[j] > 0 else "-"
    print(f"{rank+1}. {feature_names[j][:16s]} [{direction}] {loadings[j]:.4f}")
print("\n" + "-" * 65)
print("分析完成。3个主成分累计贡献率98.67%，三维可视化可清晰区分3类种子。")
```

(machine_learning_env) PS D:\Studies\机器学习\src\ch11> python task3_3.py

1. Groove Length [+] 0.7348
2. Area [-] -0.4445
3. Asymmetry Coef [-] -0.4264
4. Kernel Width [+] 0.2044
5. Kernel Length [-] -0.1936
6. Perimeter [-] -0.0266
7. Compactness [+] 0.0259

PC2 (贡献率: 17.11%):
1. Groove Length [-] -0.6708
2. Asymmetry Coef [-] -0.4762
3. Area [-] -0.4416
4. Kernel Length [-] -0.2955
5. Kernel Width [+] 0.1743
6. Perimeter [-] -0.0840
7. Compactness [-] -0.0598

PC3 (贡献率: 9.69%):
1. Compactness [+] 0.6297
2. Perimeter [+] 0.5292
3. Kernel Length [+] 0.3328
4. Kernel Width [-] -0.3327
5. Area [-] -0.2770
6. Asymmetry Coef [-] -0.1416
7. Groove Length [-] -0.0726

分析完成。3个主成分累计贡献率98.67%，三维可视化可清晰区分3类种子。

4 实验结果讨论

（讨论最终得到的结果是否合理、是否达到题目要求；分析可能的问题例如误差过大或效果不佳，分析产生的原因，探讨可能的解决方法）

本次实验分别对Iris数据集和Seeds（小麦种子）数据集进行了主成分分析（PCA）降维处理。实验结果表明，PCA能够有效提取数据的主要特征，在大幅降低数据维度的同时保留绝大部分原始信息，且降维后的可视化效果符合预期。

1. Iris数据集降维结果分析

对于4维的Iris数据集，实验结果显示前2个主成分（PC1和PC2）的累计方差贡献率高达95.81%。这意味着仅用2个新特征即可代表原始4个特征95%以上的信息量，降维效率极高。从碎石图和特征值来看，PC1（72.96%）主要综合了花瓣长度和花萼长度的信息，代表了花朵的“大小”维度；PC2（22.85%）主要反映了花萼宽度，代表了“形状”维度。可视化散点图显示，Setosa类别在PC1方向上即可完全分离，Versicolor和Virginica在PC1与PC2的联合分布下也展现出了较好的区分度，说明线性变换后的主成分空间能更紧凑地表达分类信息。

2. Seeds数据集降维结果分析

对于7维的小麦种子数据集，实验结果同样显著。前2个主成分累计贡献率为88.98%，已能满足基本的二维可视化需求；而前3个主成分累计贡献率高达98.67%，几乎无损地保留了原始数据的结构信息。在三维可视化中，Kama、Rosa和Canadian三类小麦种子呈现出明显的聚类趋势。特别是Canadian类别，在PC1方向上与其他两类分离度极高；虽然Kama和Rosa在二维平面上存在部分重叠，但在引入PC3（主要反映种子形状紧密度）后，三维空间中的区分度得到了显著提升。这证明了高维数据在降维至三维或二维时，往往需要权衡信息保留率与可视化的直观性。

3. 误差与不足

尽管PCA在去除冗余信息方面表现优异，但实验中也发现，部分样本点在主成分空间中存在投影重叠（特别是在Iris数据集的Versicolor和Virginica之间）。这可能是由于原始数据本身存在噪声，或者类别边界本身就比较模糊。此外，PCA作为一种线性降维方法，假设数据在高维空间中呈椭球状分布，若数据存在复杂的非线性流形结构（如螺旋状、环状），PCA可能无法找到最优的低维嵌入，导致信息损失。

4. 解决方法探讨

针对上述问题，未来可以尝试引入核主成分分析（Kernel PCA）来处理非线性结构的数据。同时，对于存在噪声的数据，可以在降维前增加异常值检测与清洗步骤，以提高主成分提取的准确性。

5 总结

（总结何种问题适合何种方法求解；或归纳实验过程中遇到的问题与对应的解决办法；或叙述新发现；或叙述个人的收获；或提出未解决或需研讨的问题）

通过本次实验，我深入掌握了主成分分析（PCA）算法的原理与实现细节，并对降维算法在实际数据处理中的应用有了更全面的认识。以下是具体的总结：

1. 何种问题适合何种方法求解

PCA（主成分分析）：适用于特征维度较高、特征间存在线性相关性（冗余）的问题。当需要进行数据可视化（将高维数据降至2D/3D）或去除噪声、提高后续模型训练速度时，PCA是首选的线性降维方法。

Kernel PCA（核主成分分析）：适用于数据在原始空间中非线性可分，但在高维空间中可能线性可分的情况。当PCA降维后类别重叠严重时，应考虑使用非线性降维方法。

t-SNE / UMAP：若降维的主要目的是为了可视化聚类结构（特别是对于复杂的高维流形数据），且不强调保留全局距离关系时，t-SNE或UMAP通常能产生比PCA更清晰的聚类可视化效果。

2. 实验中遇到的问题与解决办法

数据量纲不一致：原始特征（如小麦种子的Area与Compactness）数值范围差异巨大。解决办法是使用Z-score标准化（Standardization），消除量纲影响，确保协方差矩阵计算的公平性。

主成分数量确定困难：单纯依靠经验（如保留2个维度）可能导致信息丢失。解决办法是结合“累计方差贡献率（建议>85%）”、“Kaiser准则（特征值>1）”和“碎石图拐点法”三种方法综合判断。

代码实现复杂度：从零实现PCA涉及矩阵运算。解决办法是利用NumPy高效的线性代数库（如`np.linalg.eigh`）进行特征值分解，并通过面向对象编程封装成可复用的类。

3. 个人收获与新发现

收获：掌握了从数据预处理、协方差矩阵计算、特征值分解到主成分投影的完整PCA流程。学会了如何通过载荷（Loadings）分析主成分的物理意义（如PC1代表“大小”，PC2代表“形状”）。

新发现：并非所有数据集都能在二维空间完美分离。Iris数据集在2D下分离度很高，但Seeds数据集在2D下存在重叠，必须借助3D才能看清全貌。这提醒我在实际应用中，不能盲目追求低维度，而应根据累计贡献率选择最合适的维度。

4. 未解决或需研讨的问题

非线性结构的处理：本次实验数据主要呈现线性结构，若遇到复杂的非线性流形数据，PCA的效果会大打折扣。如何自动判断数据是否适合线性降维，以及如何选择最优的核函数，是值得进一步研究的问题。

主成分的可解释性：虽然PCA能生成数学上最优的主成分，但这些新特征往往是原始特征的复杂线性组合，物理意义不直观。如何在降维的同时保持一定的特征可解释性，是一个挑战。

增量式PCA：本次实验采用的是全批量计算，当数据量极大或数据流式到达时，如何利用增量式PCA（Incremental PCA）进行实时降维，是未来可以探索的方向。